

Análisis de la deforestación en la selva amazónica con técnicas de segmentación

Jose Manuel PINILLOS RUBIO¹

¹Universidad Internacional de La Rioja, Escuela Superior de Ingeniería y Tecnología (ESIT), 26006, Logroño, Spain.

unir
LA UNIVERSIDAD
EN INTERNET

RESUMEN

La deforestación en la Amazonía constituye un problema ambiental de alcance global que requiere sistemas de monitoreo precisos, transparentes y reproducibles. En este trabajo se presenta un enfoque basado en técnicas clásicas de procesamiento digital de imágenes para el análisis multitemporal de la deforestación en el Bosque Nacional Jamanxim (Brasil) a partir de una serie de veinte imágenes Landsat adquiridas entre 2000 y 2019. Se desarrolla un flujo de trabajo modular que integra transformaciones de espacio de color, mejora radiométrica selectiva, corrección de nubosidad mediante interpolación temporal y segmentación automática orientada a la generación de máscaras binarias de deforestación. A partir de estas máscaras se cuantifica la superficie afectada en kilómetros cuadrados utilizando la escala espacial de las imágenes. Los resultados muestran una tendencia de incremento sostenido de la deforestación a lo largo de dos décadas, evidenciando una transformación paisajística significativa del territorio. El enfoque propuesto demuestra que las técnicas clásicas de visión artificial pueden proporcionar estimaciones consistentes y trazables de la evolución de la cobertura forestal, constituyendo una alternativa interpretable y reproducible frente a métodos dependientes de aprendizaje supervisado.

KEYWORDS

deforestación,
mejora radiométrica,
interpolación temporal,
segmentación de
imágenes, análisis
multitemporal

I. INTRODUCCIÓN

La deforestación en la región amazónica constituye uno de los principales retos ambientales a escala global debido a sus implicaciones ecológicas, climáticas y socioeconómicas (Flores et al. (2024); Lapola et al. (2023)). La pérdida progresiva de cobertura forestal compromete la biodiversidad, altera los ciclos hidrológicos y modifica los balances de carbono, lo que hace imprescindible disponer de sistemas de monitorización rigurosos para evaluar políticas de conservación y fundamentar decisiones de gestión ambiental basadas en evidencia científica (Flores et al. (2024)). En este contexto, el Bosque Nacional Jamanxim (Brasil) destaca como un área estratégica para la conservación de la biodiversidad amazónica y un caso representativo para analizar procesos de expansión antrópica (Kinnebrew et al. (2022); Pfaff et al. (2015)).

El uso de teledetección satelital ha permitido avances significativos en el análisis multitemporal de la deforestación mediante series de imágenes de gran cobertura espacial. No obstante, su explotación sistemática presenta desafíos técnicos relevantes, como la nubosidad recurrente, la variabilidad radiométrica entre adquisiciones y las diferencias de iluminación, que pueden afectar la fiabilidad de los análisis si no se abordan adecuadamente. Aunque los enfoques basados en aprendizaje automático han mostrado un alto rendimiento en numerosos escenarios, dependen de datos etiquetados extensos y pueden plantear dificultades en términos de

interpretabilidad y reproducibilidad.

En este trabajo se adopta una perspectiva alternativa basada en **técnicas clásicas de procesamiento digital de imágenes**, priorizando la transparencia metodológica, la reproducibilidad y la interpretabilidad de los resultados. Se propone un marco de análisis estructurado y modular que integra estrategias de mejora radiométrica, tratamiento de nubosidad y segmentación automática, orientado a la obtención de máscaras binarias de deforestación coherentes en el dominio espacial y temporal.

El análisis se basa en una serie de veinte imágenes Landsat del Bosque Nacional Jamanxim (Brasil), adquiridas entre 2000 y 2019 a través del [NASA Earth Observatory](#). Esta serie temporal proporciona una cobertura espacial completa y homogénea de la región, permitiendo estudiar de manera sistemática la evolución de la cobertura forestal a lo largo de dos décadas.

A partir de esta serie temporal, el propósito de este trabajo es construir y validar un flujo de procesamiento que permita segmentar de forma automática y reproducible las áreas deforestadas, cuantificar su extensión en unidades físicas y analizar su evolución a lo largo del tiempo. Se busca disponer de un marco metodológico transparente y trazable, basado en técnicas clásicas de visión artificial, y generar estimaciones consistentes de la superficie deforestada que posibiliten extraer conclusiones cuantitativas sobre las tendencias y variaciones interanuales en el Bosque Nacional Jamanxim.

* Corresponding authors:
josemanuel.pinillos602@comunidadunir.net

II. METODOLOGÍA

Esta sección describe el enfoque desarrollado para el análisis multitemporal de deforestación en el Bosque Nacional Jamanxim, aplicando técnicas clásicas de procesamiento digital sobre una colección de imágenes satelitales obtenidas entre los años 2000 y 2019. Se han empleado transformaciones de espacio de color (escala de grises, HSV y Lab), métodos de realce y normalización tonal (CLAHE, *stretching* lineal, filtros *top-hat* y *unsharp*), algoritmos de binarización (Otsu y variantes ajustadas), y estrategias avanzadas de segmentación automática (crecimiento de regiones, *watershed*, *graph-cuts*, entre otros), con el fin de caracterizar y cuantificar las áreas deforestadas a lo largo del periodo de estudio.

Todas las etapas del procesamiento han sido diseñadas de forma modular y reproducible, evaluando cada técnica tanto de manera aislada como integrada dentro de flujos de tratamiento secuencial (*pipelines*) orientados a la mejora visual y segmentación robusta. La selección de parámetros, operadores y técnicas se ha basado en análisis comparativos sobre muestras representativas, atendiendo a criterios de coherencia espacial, respuesta estructural y estabilidad frente a variaciones de iluminación o nubosidad. A partir de esta evaluación comparativa se definió el flujo final, aplicado de forma consistente a toda la serie temporal, que permite generar una máscara binaria depurada por año y cuantificar la deforestación en km^2 mediante conteo proporcional de píxeles afectados.

A. Conjunto de imágenes

El estudio se ha desarrollado a partir de una serie de veinte imágenes multitemporales del Bosque Nacional Jamanxim (Brasil), capturadas por sensores Landsat entre los años 2000 y 2019 y disponibles públicamente a través del portal [NASA Earth Observatory](https://earthexplorer.usgs.gov/). Estas imágenes presentan resolución constante, formato RGB natural y cobertura completa de la región de estudio. En conjunto, permiten observar con claridad los cambios progresivos en la cobertura vegetal a lo largo de dos décadas.

La escala espacial aproximada de referencia utilizada es de 20 km equivalentes a 51 píxeles, lo que permite calcular con precisión el área deforestada en kilómetros cuadrados a partir de las máscaras binarias generadas por los algoritmos de segmentación. La elección de esta serie temporal responde tanto a la disponibilidad de datos limpios como a la relevancia ecológica del periodo considerado, que incluye la implementación de diversas políticas de conservación ambiental y cambios legislativos en Brasil.

B. Preprocesamiento

El análisis inicial de las imágenes satelitales requirió su conversión a distintos espacios de color, con el objetivo de facilitar la diferenciación estructural entre regiones boscosas, zonas deforestadas y formaciones nubosas. En concreto, se utilizaron los espacios HSV, escala de grises y Lab, seleccionando para cada uno de ellos aquellos canales más adecuados en función del tipo de información requerida. El espacio HSV permitió una representación explícita de la componente cromática, resultando útil para operaciones de filtrado por rango de color. El uso de imágenes en escala de grises fue especialmente apropiado para la aplicación de filtros espaciales y transformaciones

de intensidad, al reducir la complejidad visual sin pérdida de información tonal relevante. Por su parte, el espacio perceptual Lab facilitó un análisis más estable de la luminancia (canal L) y permitió aislar con precisión las regiones nubosas mediante el canal b , altamente sensible a tonalidades azuladas características de la atmósfera.

Todas las técnicas de mejora previa fueron aplicadas sobre el canal L , siguiendo una lógica orientada a la normalización del contraste y recuperación de estructuras ocultas bajo nubosidad o baja iluminación. Este procesamiento incluyó *stretching* lineal, ecualización adaptativa (CLAHE), realce por filtro *White Top-Hat* y mejora estructural mediante *Unsharp Masking*. Estas transformaciones permitieron estabilizar la respuesta tonal de cada imagen y garantizar condiciones homogéneas para la segmentación posterior, preservando la estructura espacial y la coherencia visual en toda la serie analizada.

El empleo de imágenes monocanal en estos procesos no solo reduce la complejidad computacional, sino que mejora la interpretabilidad de los resultados y garantiza una respuesta más controlada de las técnicas de procesamiento aplicadas. Según González y Woods, los métodos basados en histogramas, ajustes de contraste y filtros espaciales presentan un comportamiento más coherente cuando se aplican sobre niveles de intensidad, evitando la interferencia de componentes cromáticas no relevantes para la tarea de segmentación (Gonzalez and Woods, 2018). De forma complementaria, Poynton señala que la luminancia ofrece una respuesta tonal más estable y perceptualmente consistente, especialmente en tareas orientadas a la identificación de estructuras mediante contraste local (Poynton, 2012).




Fig. 1. Visualización de los colores de los bordes del cubo RGB en los espacios de color considerados. Fuente Jungmann et al. (2014).

En este estudio, se optó por trabajar principalmente con el espacio de color *Lab*, empleando el canal L como referencia principal para las operaciones de mejora tonal y segmentación, y el canal b para la detección de nubosidad, en línea con las recomendaciones de Sharma et al., quienes

destacan la robustez perceptual de este espacio para el análisis morfológico y la separación cromática en imágenes naturales (Sharma et al., 2005). Adicionalmente, el espacio HSV se empleó de forma complementaria en la evaluación de técnicas basadas en rangos de color, dada su separación explícita entre información de intensidad y cromaticidad (Jungmann et al., 2014).

La figura 1 ilustra la relación entre el cubo RGB y los espacios de color considerados.

C. Identificación y corrección de nubes mediante el canal b

Como se ha descrito en secciones anteriores, el canal *b* del espacio de color **Lab** presenta una respuesta radiométrica especialmente útil en el contexto de teledetección multitemporal. De forma sistemática, las nubes y las marcas gráficas superpuestas (como el número del año o la marca de agua institucional) aparecen como regiones extremadamente oscuras en este canal, lo que permite su identificación automática mediante umbralado.

Aprovechando esta propiedad, se definió una estrategia eficiente para la generación de **máscaras binarias de exclusión**, consistentes en marcar como región no válida cualquier píxel cuyo valor en el canal *b* sea inferior a un umbral de intensidad fijo. En este estudio, el valor seleccionado fue $b < 10$, tras una inspección comparativa de los histogramas de intensidad y una evaluación visual de los resultados obtenidos.

Estas máscaras se emplean como filtros posteriores en el cálculo del área deforestada, sin intervenir en la segmentación ni en el crecimiento de regiones. Aunque las esquinas de las imágenes contienen anotaciones fijas, su ubicación y forma son constantes a lo largo de toda la serie temporal, por lo que su efecto es sistemático y puede despreciarse sin impacto en la validez del análisis. No se aplicaron operaciones adicionales de eliminación manual o corrección morfológica.

Una vez generadas las máscaras binarias, se implementó una técnica de **interpolación temporal por píxel** sobre el canal de luminancia *L*, con el objetivo de restaurar la información radiométrica en aquellas regiones ocultas por nubes. Este procedimiento se aplicó exclusivamente sobre los píxeles enmascarados, manteniendo el resto de la imagen intacto para preservar la fidelidad original de la señal.

La estrategia utilizada fue la siguiente:

- Para los años intermedios (2001–2018), cada píxel contaminado se imputó mediante la **media entre el valor del año anterior y del año siguiente**, posición a posición.
- Para los años extremos (2000 y 2019), se utilizó el **valor del año más próximo** disponible como estimación.

Este enfoque garantiza la **coherencia temporal** y respeta la continuidad tonal y estructural de las regiones restauradas, sin introducir artefactos ni distorsiones globales. Además, evita la propagación de errores cromáticos o radiométricos, al trabajar exclusivamente en zonas contaminadas.

D. Técnicas de procesamiento espacial

1. Stretching lineal del histograma

Este método expande el rango dinámico mediante el remapeo lineal entre percentiles:

$$s(x, y) = \frac{r(x, y) - r_{min}}{r_{max} - r_{min}} \cdot (L - 1)$$

limitando luego los valores al rango $[0, 1]$.

2. CLAHE (Contrast Limited Adaptive Histogram Equalization)

CLAHE es una versión adaptativa de la ecualización del histograma que trabaja por bloques locales y limita el contraste para evitar amplificar ruido. Divide la imagen en **tiles** y realiza ecualizaciones locales controladas por un parámetro *clip limit*.

E. Operadores morfológicos

1. Top-hat o White top-hat

El operador **Top Hat** es una transformación morfológica que permite **resaltar detalles finos u objetos pequeños** que sobresalen respecto al fondo. Se define como la **diferencia entre la imagen original y su apertura**:

$$\text{TopHat}(A) = A - (A \circ B)$$

La apertura elimina estructuras pequeñas o finas que no se ajustan al tamaño y forma del elemento estructural. Al restar el resultado de esa apertura de la imagen original, lo que queda es precisamente aquello que la apertura ha eliminado. Es decir, se **extraen las regiones que son más pequeñas que el elemento estructural**.

Este operador es especialmente útil en situaciones donde se desea **realzar elementos pequeños, brillantes o aislados** sobre un fondo más uniforme o complejo, como puede ser el caso de letras, líneas finas, puntos brillantes o imperfecciones locales.

F. Técnicas de binarización

1. Umbral de Otsu clásico

El **umbral de Otsu** es un método automático de binarización que selecciona un valor de corte óptimo a partir del histograma de la imagen en escala de grises. Su objetivo es dividir los píxeles en dos clases (fondo y objeto) maximizando la separabilidad estadística entre ambas.

El algoritmo asume que el histograma presenta dos poblaciones de intensidades y busca el umbral *T* que maximiza la **varianza interclase**, definida como:

$$\sigma_b^2(T) = \omega_0(T) \cdot \omega_1(T) \cdot [\mu_0(T) - \mu_1(T)]^2$$

donde ω_0 y ω_1 representan las probabilidades acumuladas de las dos clases separadas por el umbral *T*, y μ_0 y μ_1 sus respectivas medias de intensidad.

El umbral óptimo T^* se obtiene como aquel que maximiza esta función de varianza interclase:

$$T^* = \arg \max_T \sigma_b^2(T)$$

Una vez determinado el umbral, la imagen binaria se genera asignando valor 1 a los píxeles con intensidad mayor o igual que T^* y 0 en caso contrario.

Su desempeño es mayor en imágenes con bimodalidad clara en el histograma, y puede verse afectado por ruido o iluminación no homogénea.

2. Otsu con ajuste de umbral

La **binarización mediante Otsu con ajuste de umbral** parte del umbral automático calculado por el método clásico, pero introduce un desplazamiento controlado para adaptar la segmentación a las características específicas de la imagen o al objetivo del análisis.

Formalmente, si T^* es el umbral obtenido por Otsu, se define un umbral ajustado como:

$$T_{adj} = T^* + \Delta$$

donde Δ es un parámetro de desplazamiento que permite hacer la segmentación más o menos restrictiva. Un valor positivo de Δ eleva el umbral, reduciendo el número de píxeles clasificados como objeto, mientras que un valor negativo lo disminuye, ampliando la región segmentada.

La imagen binaria final se obtiene aplicando este umbral modificado:

$$B(x, y) = \begin{cases} 1 & \text{si } r(x, y) \geq T_{adj} \\ 0 & \text{en caso contrario} \end{cases}$$

Este enfoque resulta especialmente útil cuando el umbral de Otsu puro no se ajusta perfectamente a la separación deseada entre regiones, permitiendo introducir conocimiento experto o calibración empírica sin abandonar la base estadística del método.

3. Binarización por rango de color en el espacio HSV

La **binarización por rango de color en el espacio HSV** se basa en la separación explícita de la información cromática y de luminancia para segmentar regiones de interés según su tonalidad, saturación y brillo. A diferencia de los métodos basados únicamente en intensidad, este enfoque explota la estructura perceptual del color.

El espacio HSV descompone cada píxel en tres componentes:

- **Hue (H)**: tono o matiz dominante del color.
- **Saturation (S)**: pureza o intensidad del color.
- **Value (V)**: nivel de brillo o luminancia.

La segmentación se realiza definiendo un intervalo de valores admisibles para cada canal, estableciendo un rango tridimensional en el espacio HSV:

$$\begin{bmatrix} H_{\min} \\ S_{\min} \\ V_{\min} \end{bmatrix} \leq \begin{bmatrix} H(x, y) \\ S(x, y) \\ V(x, y) \end{bmatrix} \leq \begin{bmatrix} H_{\max} \\ S_{\max} \\ V_{\max} \end{bmatrix}$$

La máscara binaria resultante se define como:

$$B(x, y) = \begin{cases} 1 & \text{si el píxel pertenece al rango HSV definido} \\ 0 & \text{en caso contrario} \end{cases}$$

Este método puede ser eficaz cuando el objeto de interés presenta características cromáticas diferenciadas respecto al fondo, permitiendo discriminar regiones con independencia de variaciones moderadas de iluminación. No obstante, su

rendimiento puede verse afectado por sombras, cambios de iluminación o mezclas de color complejas, lo que requiere una selección cuidadosa de los umbrales en cada caso.

G. Técnicas clásicas de segmentación

1. Segmentación por crecimiento de regiones basado en semillas

El **crecimiento de regiones basado en semillas** es un método de segmentación *bottom-up* que parte de uno o varios píxeles iniciales, denominados *semillas*, y expande iterativamente regiones homogéneas a partir de ellos.

El algoritmo analiza los píxeles vecinos de cada semilla y decide su incorporación a la región en función de una medida de similitud basada en intensidad, color o textura. Un píxel se añade si su diferencia respecto a la región es inferior a un umbral predefinido, repitiéndose el proceso hasta que no existen más vecinos que cumplan el criterio.

El resultado depende fuertemente de la posición inicial de las semillas y del umbral de similitud utilizado. Este método es eficaz en imágenes de alto contraste, pero presenta un coste computacional elevado y riesgo de sobresegmentación en presencia de pequeñas variaciones locales.

2. Segmentación mediante Split and Merge

El enfoque de **Split and Merge** combina dos fases complementarias de división y fusión para equilibrar precisión y eficiencia en la segmentación.

- En la fase de *split*, la imagen se divide recursivamente en regiones más pequeñas siguiendo criterios de homogeneidad, normalmente mediante una estructura jerárquica tipo árbol.
- En la fase de *merge*, las regiones resultantes se fusionan cuando presentan propiedades estadísticas similares.

El método permite controlar el nivel de detalle y puede paralelizarse en la fase de división, pero una vez separadas dos regiones en ramas distintas de la jerarquía, su fusión directa no siempre es posible sin postprocesado adicional.

3. Segmentación por contornos activos (Gradient Vector Flow, GVF)

El **GVF** pertenece a la familia de los modelos de contorno activo (*snakes*) y segmenta la imagen mediante la evolución de una curva inicial que se adapta dinámicamente a los bordes del objeto.

El método minimiza una función de energía compuesta por tres términos:

$$E = \int_0^1 (E_{\text{int}}(v(s)) + E_{\text{imagen}}(v(s)) + E_{\text{con}}(v(s))), ds$$

donde E_{int} controla la suavidad del contorno, E_{imagen} lo atrae hacia los bordes y E_{con} modela influencias externas para capturar concavidades y estructuras complejas.

GVF permite converger correctamente incluso cuando el contorno inicial está lejos del borde real, pero presenta elevada complejidad computacional y requiere una inicialización y parametrización cuidadosas.

4. Segmentación morfológica *Watershed* (cuenca hidrográfica)

El algoritmo de *Watershed* interpreta la imagen en niveles de gris como un relieve topográfico, donde la intensidad representa la altura del terreno.

Cada mínimo local define una cuenca de captación, y la segmentación se obtiene simulando una inundación progresiva desde dichos mínimos. Cuando dos regiones están a punto de fusionarse, se levantan diques que definen las líneas de *Watershed*, que actúan como fronteras entre regiones.

El método produce segmentaciones muy detalladas y con límites bien definidos, pero es altamente susceptible a la sobresegmentación en presencia de ruido, por lo que suele combinarse con suavizado previo o con *Watershed* basado en marcadores.

5. Segmentación basada en grafos

En los métodos basados en grafos, cada píxel se modela como un nodo conectado a sus vecinos mediante aristas ponderadas por una medida de similitud (intensidad, color o textura).

La segmentación se obtiene eliminando las conexiones más débiles, lo que divide el grafo en componentes conexas que corresponden a regiones homogéneas. Este enfoque integra información local y global, proporcionando resultados robustos en escenarios complejos.

Dentro de esta familia destacan dos enfoques principales: *Graph-Cuts* y agregación multiescala.

5.1 *Graph-Cuts*

Los métodos de *Graph-Cuts* formulan la segmentación como un problema de optimización global sobre un grafo construido a partir de la imagen.

Cada píxel es un nodo y las aristas representan relaciones de similitud con sus vecinos. El algoritmo busca el corte mínimo que separa el grafo en regiones coherentes minimizando una función de coste que equilibra fidelidad a los datos y suavidad espacial.

Este enfoque produce segmentaciones globalmente óptimas, pero su rendimiento depende fuertemente de la definición de la función de coste y puede ser computacionalmente exigente para imágenes de gran tamaño.

5.2 Agregación multiescala

La **agregación multiescala** construye la segmentación de forma jerárquica, agrupando píxeles por similitud y generando representantes a distintas escalas.

En cada iteración, se fusionan nodos vecinos similares y se calcula un nodo representante (normalmente su media), reduciendo progresivamente la complejidad del grafo. El proceso se repite hasta cumplir un criterio de parada basado en calidad o número de regiones.

Finalmente, la segmentación se obtiene deshaciendo las agrupaciones jerárquicas. El método es estable y flexible, pero puede perder detalle fino si la agregación inicial es demasiado agresiva.

III. RESULTADOS

Esta sección presenta los resultados derivados de la aplicación del flujo de procesamiento y segmentación propuesto, combinando análisis cualitativo y cuantitativo para evaluar la calidad de las segmentaciones y la fiabilidad de las métricas obtenidas.

A. Mejora previa mediante técnicas de procesamiento radiométrico y estructural

La normalización del histograma mediante **stretching lineal** permitió una expansión global del rango dinámico en las imágenes originales, mejorando el contraste general, especialmente en zonas oscuras y homogéneas del dosel forestal. Esta transformación favoreció la diferenciación tonal entre regiones boscosas y áreas deforestadas, que pasaron a presentar valores más altos de luminancia. Sin embargo, el carácter global de esta técnica limitó su eficacia en áreas con patrones locales complejos o iluminación no homogénea, como bordes de caminos o franjas de tala reciente (Fig. 6).

La posterior aplicación de **CLAHE** (*Contrast Limited Adaptive Histogram Equalization*) sobre el canal *L* proporcionó una mejora localizada del contraste, corrigiendo las limitaciones del enfoque anterior. Se observó una intensificación de las diferencias radiométricas entre zonas deforestadas y vegetación circundante, incluso en áreas con bajo contraste inicial. Esta técnica evitó la sobresaturación del fondo y mantuvo la estructura tonal de las imágenes, logrando una distribución de intensidades más uniforme y perceptualmente relevante (Fig. 7).

Los histogramas asociados confirman que CLAHE redistribuye los niveles de intensidad de forma más homogénea y progresiva que el *stretching* lineal, aumentando la separabilidad radiométrica sin introducir artefactos abruptos. En vista de estos resultados, **se seleccionó CLAHE como técnica preferente de mejora tonal** dentro del flujo de trabajo, por su capacidad para realzar estructuras relevantes sin comprometer la estabilidad visual global.

A continuación, se evaluó el efecto del operador morfológico **White Top-Hat** aplicado sobre las imágenes ya procesadas con CLAHE. Esta transformación resultó especialmente eficaz para resaltar estructuras brillantes de pequeño tamaño, asociadas a claros abiertos en el bosque, caminos de acceso y parcelas recientes de deforestación. La respuesta fue particularmente robusta en zonas periféricas y fragmentadas, donde el patrón de tala no sigue un trazado regular. El fondo boscoso, más homogéneo y oscuro, actuó como referencia estructural que permitió al filtro enfatizar las anomalías luminosas asociadas a actividad antrópica (Fig. 8).

Finalmente, la aplicación de **Unsharp Masking** sobre las imágenes previamente realizadas contribuyó a reforzar los contornos y mejorar la definición de los límites entre regiones forestadas y deforestadas. Esta técnica resultó especialmente útil en áreas donde las transiciones tonales eran difusas o poco marcadas, como zonas de borde o caminos interiores. A nivel visual, se observó una nitidez mayor en las formas lineales o angulosas características de la expansión humana, sin introducir halos significativos ni alterar el equilibrio radiométrico global (Fig. 9).

El análisis combinado de los resultados sugiere que la **secuencia óptima de mejora previa** incluye la aplicación de CLAHE, seguida del filtro *White Top-Hat* y, finalmente, *Unsharp Masking*. Este flujo garantiza un equilibrio adecuado entre realce global y local, aumentando la visibilidad de estructuras clave sin comprometer la estabilidad tonal ni introducir ruido artificial. Las transformaciones aplicadas sobre el canal de luminancia del espacio Lab demuestran ser más eficaces que las implementadas en escala de grises tradicional, gracias a su fidelidad perceptual y a la capacidad de preservar la geometría radiométrica original de las imágenes.

B. Evaluación de técnicas de binarización para la detección de deforestación

Tras aplicar distintos enfoques de binarización sobre las imágenes previamente realzadas (canal L con CLAHE, filtro *White Top-Hat* y *Unsharp Masking*), se obtuvieron resultados diferenciados en función del año y del método empleado. La figura 10 muestra comparativamente los resultados obtenidos con cada técnica para los años 2000, 2010 y 2019.

En primer lugar, la binarización automática mediante el método de **Otsu** permitió una segmentación razonable en los años más recientes, en los que la deforestación ha generado patrones más evidentes de luminancia. En 2010 y 2019, las diferencias tonales entre áreas taladas y vegetación densa son suficientes para que el umbral global calculado por el algoritmo separe adecuadamente ambas clases. Sin embargo, en el año 2000 el contraste general de la imagen es más bajo, lo que provoca una *subsegmentación* de las zonas deforestadas y una pérdida significativa de información relevante.

Para mitigar esta limitación, se ensayó una **versión ajustada de Otsu** que incorpora un *offset* positivo al umbral calculado automáticamente. Esta modificación mejora notablemente el resultado en la imagen de 2000, recuperando áreas previamente excluidas y delimitando con mayor precisión las regiones de interés. En los años posteriores, esta estrategia conserva la coherencia de las máscaras sin introducir artefactos, manteniendo un equilibrio adecuado entre sensibilidad y especificidad. Esta variante se muestra más robusta frente a condiciones de iluminación desfavorables y constituye una mejora significativa respecto al método base.

Como tercera estrategia, se evaluó una **binarización por rango de color en el espacio HSV**, orientada a capturar tonalidades asociadas a suelos descubiertos (marrones claros) o áreas recientemente intervenidas. Este enfoque se basa en la segmentación cromática directa y requiere una calibración cuidadosa del rango de matices seleccionados. Si bien en 2010 y 2019 se identifican correctamente algunas estructuras lineales características de la expansión antrópica, en 2000 la segmentación presenta una alta tasa de falsos positivos y fragmentación morfológica, probablemente debido a la alteración cromática generada por nubosidad o sombras. Esta técnica, aunque útil en ciertos contextos, resulta demasiado dependiente de las condiciones atmosféricas y de la homogeneidad espectral de cada imagen.

Los resultados confirman que la **binarización mediante Otsu con ajuste de umbral** constituye la opción más fiable

y reproducible en el contexto de este estudio para este tipo de análisis multitemporal. Su adaptabilidad a distintos rangos de luminancia y su capacidad para preservar la geometría original de las áreas deforestadas la convierten en una herramienta eficaz para la generación de máscaras de trabajo consistentes, minimizando la sensibilidad a condiciones particulares de cada escena.

C. Evaluación comparativa de algoritmos de segmentación

La aplicación de distintos enfoques clásicos de segmentación sobre las imágenes binarizadas evidenció comportamientos muy diferenciados en términos de estabilidad espacial, coherencia geométrica y utilidad semántica para la detección de deforestación.

El método de **crecimiento de regiones basado en semillas** proporcionó los resultados más consistentes y reproducibles a lo largo de toda la serie temporal. Las máscaras obtenidas mostraron geometrías limpias, contornos bien definidos y una correspondencia visual directa con las estructuras reales de deforestación observadas en las imágenes originales. Asimismo, se observó una continuidad espacial adecuada entre regiones adyacentes y una reducción notable de fragmentaciones aisladas, lo que facilitó el posterior cálculo de métricas cuantitativas y el análisis longitudinal del fenómeno.

En contraste, la segmentación mediante *contornos activos* (*Gradient Vector Flow*) no resultó adecuada para este tipo de imágenes. El modelo mostró una capacidad de adaptación muy limitada, con evoluciones de la curva restringidas a zonas homogéneas y sin alineación con los límites reales de las áreas deforestadas. Como consecuencia, las segmentaciones obtenidas carecieron de relevancia morfológica y fueron descartadas para el análisis final.

El enfoque de *Split and Merge* tampoco resultó apropiado para este contexto. La dependencia de una división inicial en bloques cuadrados generó regiones artificiales que no se corresponden con la morfología irregular de las zonas deforestadas, produciendo segmentaciones poco representativas de la estructura real del territorio.

Por su parte, la segmentación mediante *Watershed* presentó una marcada tendencia a la sobresegmentación, incluso tras aplicar suavizado previo. La presencia de numerosos mínimos locales asociados a texturas, sombras y heterogeneidades naturales indujo la creación de múltiples regiones irrelevantes, lo que limitó su utilidad como método principal de segmentación multitemporal.

Finalmente, los métodos basados en grafos (*Graph Cuts* y agregación multiescala) tampoco ofrecieron resultados satisfactorios. En el caso de *Graph Cuts*, la ausencia de una función de datos supervisada o de semillas informativas condujo a agrupaciones triviales con baja capacidad de discriminación estructural. La agregación multiescala, por su parte, tendió a fusionar en exceso regiones con características distintas, diluyendo las fronteras entre áreas forestadas y deforestadas. En ambos casos, las particiones resultantes carecieron de significado semántico para el problema analizado.

En conjunto, la comparación sistemática de estos enfoques confirma que la combinación de **binarización mediante Otsu con ajuste de umbral** seguida de

crecimiento de regiones desde semillas completas constituye la estrategia más eficaz, precisa y coherente con la naturaleza del fenómeno estudiado. Este enfoque garantizó segmentaciones continuas, estructuradas y estables entre años, preservando fielmente la geometría de las zonas deforestadas y proporcionando una base sólida para el análisis cuantitativo posterior.

D. Evaluación de la corrección de nubes e interpolación temporal

Los resultados obtenidos tras aplicar un umbral de intensidad de $b < 10$ sobre el canal b permiten generar máscaras binarias robustas, en las que se identifican de forma precisa las regiones contaminadas por nubes y elementos gráficos sobresaturados. Tal como se aprecia en las imágenes correspondientes a los años 2001, 2010 y 2019 de la figura 11, las zonas afectadas aparecen claramente delimitadas como regiones blancas sobre fondo negro.

Los resultados evidencian que la interpolación mantiene la estructura geométrica de los patrones de deforestación y no introduce cambios perceptibles en la radiometría de las áreas no enmascaradas.

La técnica empleada ha demostrado ser robusta ante variaciones interanuales y mantiene la estructura geométrica de los patrones de deforestación. Al limitar la interpolación exclusivamente a los píxeles no válidos, se garantiza que el resto de la imagen conserve su integridad radiométrica original.

E. Evolución temporal y análisis del área deforestada (2000–2019)

La figura 2 muestra la **evolución anual del área deforestada** en el Bosque Nacional Jamanxim entre los años 2000 y 2019. Las barras indican la superficie deforestada anual en kilómetros cuadrados, mientras que las etiquetas sobre cada barra representan el *porcentaje que dicha superficie ocupa respecto al área total visible* (aproximadamente 89.000 km²).




Fig. 2. Evolución porcentual del área deforestada (2000–2019).

Desde una perspectiva cuantitativa y temporal, se observa una **tendencia general de incremento sostenido**. En el periodo 2000–2003 la deforestación se mantiene en valores bajos (entre un 3% y 4% del total), mientras que a partir de 2006 se estabiliza en torno al 7–8.5%, y en el periodo final 2014–2019 se superan los valores críticos del 10%, alcanzando su máximo en 2019 con 9.838 km² (11.1% del total).

El análisis conjunto con la curva de variación porcentual interanual permite identificar patrones de aceleración y contención del fenómeno. En particular:

- **Incrementos acusados:** destacan los años 2004 (+45.2%), 2014 (+25.5%), 2011 (+14.6%) y 2019 (+12.7%), asociados a fuertes pulsos de expansión.
- **Descensos puntuales:** los años 2001 (−7.0%), 2003 (−7.3%), 2010 (−5.1%), 2015 (−20.1%) y 2018 (−7.6%) registran reducciones, aunque sin revertir la tendencia global.
- **Tendencia de fondo:** el área deforestada se ha multiplicado por más de tres, pasando de menos de 3.000 km² en 2000 a casi 10.000 km² en 2019.

En la figura 3 se representa la **distribución de la superficie por estado de cobertura forestal** en los años extremos de la serie. Se observa que:

- En 2000, el 96.7% del territorio estaba cubierto por vegetación, con solo un 3.3% deforestado.
- En 2019, el área deforestada alcanza el 11.1%, lo que representa una pérdida acumulada de 6.941 km².




Fig. 3. Distribución de la cobertura terrestre en 2000 y 2019.

La figura 4 refuerza esta evolución con un gráfico centrado en el **porcentaje anual de superficie deforestada**, donde se confirma visualmente la escalada progresiva del fenómeno.




Fig. 4. Área deforestada anual y variación porcentual interanual.

Finalmente, en la figura 5 se presenta la **variación absoluta interanual**, mostrando la diferencia en km² de un año respecto al anterior. Esta vista permite evaluar la volatilidad del fenómeno:

- **Máximos incrementos:** 2014 (+1.936 km²), 2004 (+1.516 km²) y 2016 (+1.027 km²).

- **Mayores reducciones:** 2015 (-1.953 km^2), 2018 (-755 km^2) y 2010 (-372 km^2).




Fig. 5. Variación interanual absoluta del área deforestada.

Nota. Las versiones ampliadas de las figuras presentadas en esta sección se incluyen en el Anexo para facilitar su inspección visual detallada sin interrumpir la continuidad del texto principal.

IV. CONCLUSIONES

Los resultados obtenidos en esta actividad demuestran que es posible realizar un análisis multitemporal riguroso de la deforestación utilizando técnicas clásicas de procesamiento de imágenes, siempre que se implemente un flujo de trabajo estructurado y adaptado a las limitaciones propias de las imágenes satelitales. En particular, los principales desafíos del dominio —nubosidad recurrente, variabilidad radiométrica interanual y bajo contraste estructural en determinadas zonas— pudieron ser abordados de forma efectiva mediante un *pipeline* secuencial que integra interpolación temporal, mejora tonal selectiva y segmentación binaria robusta.

En primer lugar, la mejora del canal de luminancia (L) en el espacio Lab , basada en la combinación de CLAHE, filtrado morfológico *Top-Hat* y *Unsharp Masking*, resultó determinante para estabilizar la respuesta radiométrica entre años y aumentar la separabilidad visual entre áreas forestadas y deforestadas. Este tratamiento permitió recuperar detalles relevantes en zonas afectadas por sombras, variaciones atmosféricas o degradación radiométrica, garantizando la coherencia tonal necesaria para un análisis comparativo fiable.

Asimismo, el uso del canal b del espacio Lab se reveló particularmente eficaz para la identificación automática de regiones no válidas asociadas a nubes y elementos gráficos superpuestos. La generación de una máscara de exclusión basada en umbralado, combinada con una estrategia de interpolación temporal guiada por años adyacentes, permitió restaurar información en zonas contaminadas sin comprometer la continuidad espacial ni la coherencia temporal de la serie. Este procedimiento evitó la necesidad de descartar imágenes completas y aseguró la integridad del análisis multitemporal.

Una vez corregidas las imágenes a nivel radiométrico, la binarización mediante un umbral de Otsu con desplazamiento controlado proporcionó un equilibrio adecuado entre sensibilidad y especificidad en la detección de áreas deforestadas. Sobre esta base, la **evaluación comparativa de algoritmos de segmentación** evidenció que

no todos los enfoques clásicos son igualmente adecuados para este tipo de imágenes.

En concreto, métodos como *Split and Merge*, *Watershed* o modelos de contorno activo (*GVF*) resultaron poco apropiados en este contexto debido a su dependencia de divisiones geométricas rígidas, su tendencia a la sobresegmentación o su sensibilidad a la falta de gradientes en mapas binarios. De igual modo, enfoques basados en grafos como *Graph Cuts* o agregación multiescala no ofrecieron particiones semánticamente útiles sin la incorporación de información supervisada adicional.

Por el contrario, la combinación de **binarización mediante Otsu con ajuste de umbral seguida de crecimiento completo de regiones desde semillas** demostró ser la estrategia más eficaz, estable y coherente con la naturaleza del fenómeno estudiado. Este enfoque permitió consolidar las regiones deforestadas, eliminar fragmentaciones residuales y generar máscaras finales continuas y espacialmente coherentes, adecuadas para el cálculo preciso del área deforestada.

Desde el punto de vista cuantitativo, el análisis temporal evidenció un avance claro y progresivo de la deforestación entre 2000 y 2019. La superficie deforestada pasó de **2896.89 km^2 en 2000 a 9838.06 km^2 en 2019**, lo que representa un incremento acumulado superior a **6900 km^2** . A nivel relativo, la proporción del área afectada se triplicó, pasando del 3.3% al 11.1% del total visible. No obstante, esta tendencia no fue lineal: años como 2004 y 2014 mostraron aumentos abruptos (+45.2% y +25.5%, respectivamente), mientras que en 2015 se registró una reducción significativa (−20.1%), posiblemente vinculada a políticas de conservación o condiciones climáticas atípicas.

Estos resultados validan la hipótesis de que un flujo de procesamiento estructurado y reproducible puede proporcionar estimaciones precisas y consistentes de la evolución de la cobertura forestal a lo largo del tiempo. El sistema desarrollado permite identificar tendencias, comparar años clave y visualizar el impacto acumulado de la deforestación con un alto nivel de detalle espacial y temporal.

Desde una perspectiva operativa, el enfoque propuesto destaca por su **transparencia metodológica, reproducibilidad y capacidad para operar sobre datos reales sin necesidad de aprendizaje supervisado ni anotaciones manuales**, lo que lo convierte en una herramienta adecuada para tareas de monitoreo ambiental en contextos donde la escalabilidad y la interpretabilidad son prioritarias.

REFERENCES

- Flores, B. M., Montoya, E., Sakschewski, B., Nascimento, N., Staal, A., Betts, R. A., Levis, C., Lapola, D. M., Esquivel-Muelbert, A., Jakovac, C., Nobre, C. A., Oliveira, R. S., Borma, L. S., Nian, D., Boers, N., Hecht, S. B., ter Steege, H., Arieira, J., Lucas, I. L., Berenguer, E., Marengo, J. A., Gatti, L. V., Mattos, C. R., and Hirota, M. (2024). Critical transitions in the amazon forest system. *Nature* 2024 626:7999, 626:555–564.

- Gonzalez, R. C. and Woods, R. E. (2018). *Digital image processing*. Pearson.
- Jungmann, A., Jatzkowski, J., and Kleinjohann, B. (2014). Evaluation of color spaces for robust image segmentation. In *2014 International Conference on Computer Vision Theory and Applications (VISAPP)*, volume 1, pages 648–655.
- Kinnebrew, E., Ochoa-Brito, J. I., French, M., Mills-Novoa, M., Shoffner, E., and Siegel, K. (2022). Biases and limitations of global forest change and author-generated land cover maps in detecting deforestation in the amazon. *PLOS ONE*, 17:e0268970.
- Lapola, D. M., Pinho, P., Barlow, J., Aragão, L. E., Berenguer, E., Carmenta, R., Liddy, H. M., Seixas, H., Silva, C. V., Silva, C. H., Alencar, A. A., Anderson, L. O., Armenteras, D., Brovkin, V., Calders, K., Chambers, J., Chini, L., Costa, M. H., Faria, B. L., Fearnside, P. M., Ferreira, J., Gatti, L., Gutierrez-Velez, V. H., Han, Z., Hibbard, K., Koven, C., Lawrence, P., Pongratz, J., Portela, B. T., Rounsevell, M., Ruane, A. C., Schaldach, R., da Silva, S. S., von Randow, C., and Walker, W. S. (2023). The drivers and impacts of amazon forest degradation. *Science*, 379.
- Pfaff, A., Robalino, J., Herrera, D., and Sandoval, C. (2015). Protected areas’ impacts on brazilian amazon deforestation: Examining conservation – development interactions to inform planning. *PLOS ONE*, 10:e0129460.
- Poynton, C. (2012). Digital video and hd: Algorithms and interfaces. *Digital Video and HD: Algorithms and Interfaces*, pages 1–709.
- Sharma, G., Wu, W., and Dalal, E. N. (2005). The ciede2000 color-difference formula: Implementation notes, supplementary test data, and mathematical observations. *Color Research & Application*, 30:21–30.




Fig. 6. Imágenes del canal L tras la aplicación de *stretching* lineal y sus histogramas asociados.




Fig. 7. Imágenes del canal L tras la aplicación de CLAHE y sus histogramas asociados.




Fig. 8. Resultado de la transformación White Top-Hat sobre el canal L.




Fig. 9. Resultado del filtro Unsharp Masking aplicado al canal L.




Fig. 10. Resultado de la aplicación de los diferentes tipos de binarización.




Fig. 11. Máscara final de nubosidad generada mediante umbralización del canal b en Lab.




Fig. 12. Reconstrucción del canal L mediante interpolación guiada por la máscara de nubosidad del canal b .




Fig. 13. Evolución porcentual del área deforestada (2000–2019) — versión ampliada.




Fig. 14. Distribución de la cobertura terrestre en 2000 y 2019 — versión ampliada.




Fig. 15. Área deforestada anual y variación porcentual interanual — versión ampliada.




Fig. 16. Variación interanual absoluta del área deforestada — versión ampliada.